Layer14 qkv_v HMMA 注错：C0–C3 全链路多检查点报告

日期：2026-10-22
模型：Qwen2.5-1.5B-Instruct
注入：layer14 qkv_v，HMMA destination register，1 bit/run
范围：**不注 layer0/27；不扩 bit24–27；只跑一个 block 注入 + clean downstream**

---

1. 实验范围

只在 **layer 14 的 qkv_v** 注入：

```
V = X_norm × W_v
X_norm: [2264, 1536]
W_v:    [1536, 256]
V:      [2264, 256]
```

注入后继续运行 clean 的 layer15–27，直到 layer27 输出。

四个检查点：

检查点	内容
C0	layer14 qkv_v GEMM 输出 V
C1	layer14 attention 模块输出，Wo 后
C2	layer14 Transformer block 输出
C3	layer27 最终 Transformer block 输出

C3 不接 final norm、LM head 或 decode。

---

2. 注入矩阵

```
layer14 × 3 bits × 60 random HMMA sites
= 180 个 fault run
```

- bit：28 / 29 / 30；
- 每 run 只翻 1 bit；
- 随机 HMMA destination-register 站点；
- 不做 early/middle/late 分层；
- 不扩 bit24–27；
- 不向 layer0/27 注入；
- 405/405 的旧实验不再混入本报告。

---

3. 控制组

控制	结果
clean 全链路（layer14→27）	**30/30** bitwise 一致
sham（DUMMY injector，不翻 bit）	**27/27** 全部 Masked
sham 注入日志	27/27 出现 `Injection data`
fault 注入	**180/180** 成功
invalid injection	0
crash	**0/180**

clean 和 sham 不进入 fault 分母。

---

4. 分类定义

D0：无软件检测器

```
crash / runtime error / 无输出 → Crash
正常结束，C0–C3 与 golden bitwise 不同 → SDC
正常结束，C0–C3 与 golden bitwise 相同 → Masked
```

D0 下 NaN/Inf 但程序正常结束仍计入 SDC。

D1：NaN/Inf 检测器

```
Crash → Crash
检测到 NaN/Inf → DUE
正常但输出不同 → SDC
正常且输出相同 → Masked
```

D1 是离线敏感性分类，不混入 D0 主表。

---

5. 主结果

5.1 D0

四个检查点结果一致：

检查点	SDC	Masked	DUE	Crash
C0 GEMM V	179	1	0	0
C1 attention	179	1	0	0
C2 layer14 block	179	1	0	0
C3 layer27 block	179	1	0	0

```
SDC   = 179/180 = 99.44%
Masked=   1/180 = 0.56%
DUE   =   0/180
Crash =   0/180
```

5.2 D1

检查点	SDC	DUE	Masked	Crash
C0 GEMM V	173	6	1	0
C1 attention	173	6	1	0
C2 layer14 block	173	6	1	0
C3 layer27 block	173	6	1	0

6 个 DUE 全部来自 bit30，且 C0–C3 全部为 NaN/Inf。

5.3 按 bit

bit	D0 SDC	D0 Masked	D1 DUE
28	60	0	0
29	60	0	0
30	59	1	6

bit28/29 没有 Masked；唯一的 Masked 是 bit30 的零累加器站点。

---

6. 多维度 golden vs actual

下表基于 D0 的 179 个 SDC。
`mismatch` 是 C0–C3 各自与 golden 不同的元素数量；误差为有限值。

检查点	mismatch 中位数	mismatch 最小值	mismatch 最大值	maxabs 中位数	maxabs 最大值	>1e10 数量	rel_l2 中位数
C0 GEMM V	**1**	1	1	0.444	3.06e38	52	6.03e-4
C1 attention	**31,344**	248	3,477,504	0.03125	3.11e37	52	3.99e-4
C2 layer14 block	**86,663**	1,252	3,477,504	0.125	3.11e37	52	9.96e-5
C3 layer27 block	**1,555,001**	42,824	3,477,504	5.0	3.11e37	52	9.60e-3

6.1 关键数值现象

- C0 每次都只有 **1 个 V 元素**改变；
- 但到 C1，中位数已经扩散到 **31,344** 个元素；
- C2 中位数 **86,663**；
- C3 中位数 **1,555,001**，接近 348 万元素的一半；

- C3 的 `rel_l2` 中位数从 C0 的 `6e-4` 上升到 `9.6e-3`；
- C3 的最大绝对误差约 `3.1e37`；
- 52 个 SDC 在 C0–C3 都出现 `maxabs > 1e10`，主要来自 bit30。

C1/C2 的 `maxabs 中位数` 比 C0 小，不代表误差变小；它是因为 C0 的单一元素误差被 BF16 attention/残差重新分配后，最大单元素值不同。传播范围（mismatch）更直接地显示错误在扩大。

---

7. 传播矩阵

四个检查点的 D0 结果完全一致：

```
C0 SDC → C1 SDC → C2 SDC → C3 SDC
C0 Masked → C1 Masked → C2 Masked → C3 Masked
```

本样本中没有出现：

- C0 已改变但 C1 恢复；
- C1 已改变但 C2 恢复；
- C2 已改变但 C3 恢复；
- 上游 Masked 但下游 SDC。

也就是说，在高 bit、单 bit、单 block 注入下，只要 V 输出改变，错误就一路传播到 layer27。

7.1 唯一的 Masked

站点：

```
L14_b30_055
before = 0x0
after  = 0x40000000
```

累加器原本是 0，翻转 bit30 后 BF16 输出仍为 0，因此 C0–C3 全部 Masked。

7.2 6 个 DUE

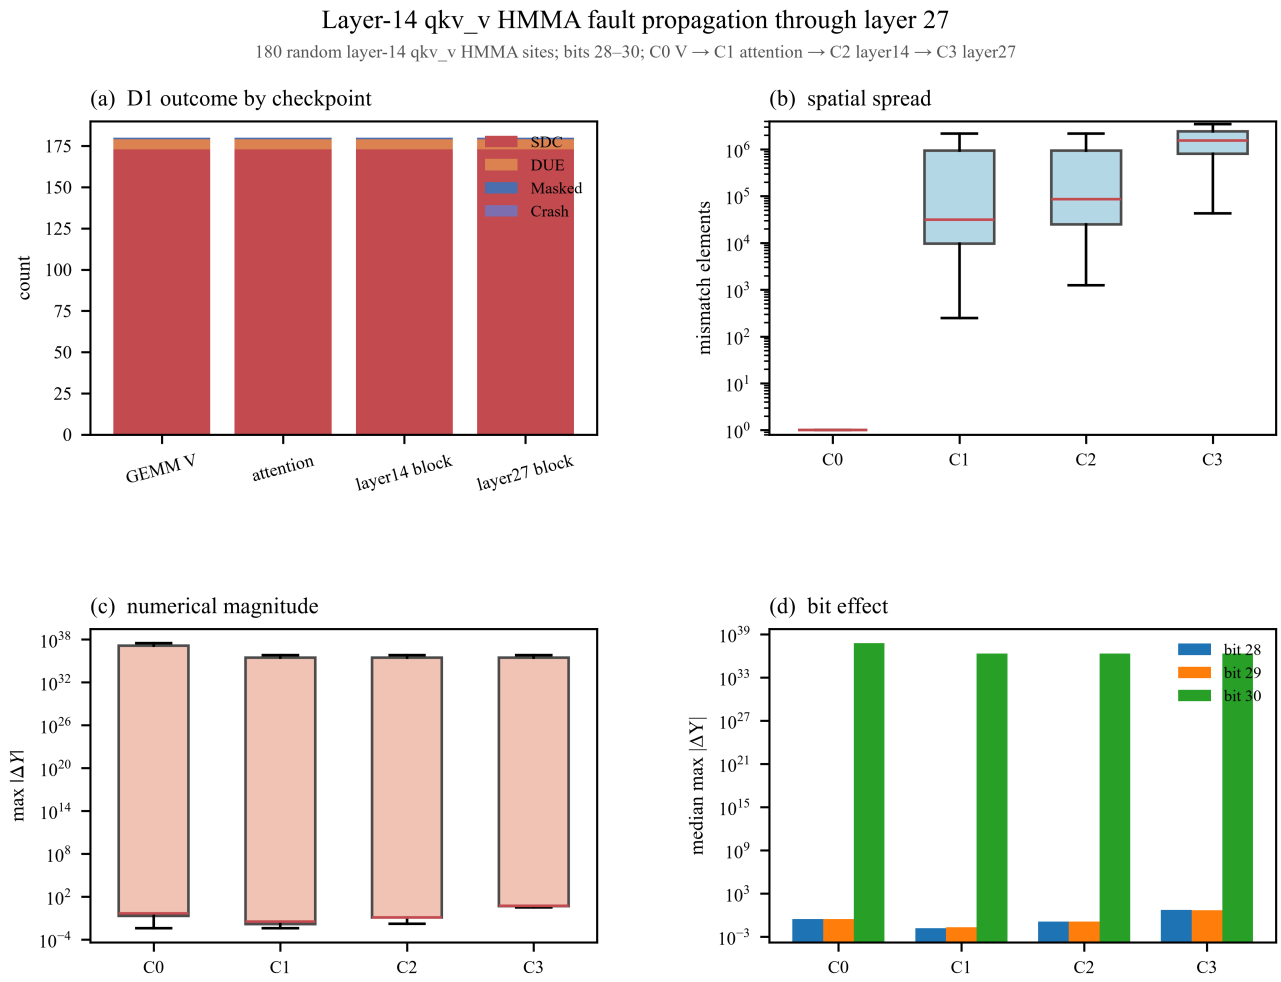
6 个站点全部是 bit30，且在 C0/C1/C2/C3 都出现 NaN/Inf：

```
L14_b30_000
L14_b30_020
L14_b30_037
L14_b30_045
L14_b30_048
L14_b30_053
```

D0 下它们是 SDC；D1 的 NaN/Inf 检测把它们归为 DUE。

---

8. 图示



D1: NaN/Inf detector. Clean 30/30; sham 27/27. No layer0/27 injection; no bit24–27.

矢量版：

`figures/qkv_v_fullstack_summary.pdf`

图中：

- (a) D1 下 C0–C3 的 SDC/DUE/Masked/Crash；
- (b) C0–C3 的 mismatch 元素数量；
- (c) C0–C3 的 max |ΔY| 分布；
- (d) bit28/29/30 的 C0–C3 中位 max |ΔY|。

---

9. 与之前单 block 结果的区别

之前只看 layer14 block 内部：

```
V → attention → layer14 block
```

本实验新增：

```
layer14 block → clean layer15–27 → layer27 block
```

因此可以回答：

- 错误是否会穿过后续 13 层；
- 在 layer27 是否仍然可见；
- C3 的数值误差是否比 C0 更大；
- 单元素 V 错误如何扩散到全序列。

本实验不能回答：

- 最终 answer 是否正确；
- layer0/27 注入的敏感性；
- 低 bit 的影响；
- 其它 GEMM stage。

---

10. 局限

- 只注入 layer14；
- 只测一个 2,264-token case；
- 只测 bit28–30；
- 每 run 只翻 1 bit；
- C3 是 layer27 block 输出，不是完整 Qwen 生成结果；
- C1 是 attention 输出（Wo 后），不是原始 attention score；
- downstream layer15–27 是 clean 运行，不含注入；
- D1 是离线 NaN/Inf 检测，不是实际硬件 ECC；
- 不能把结果外推到 layer0/27 注入或其它 stage。

---

11. 产物

产物	路径
180 个 fault run	`results/qkv_v_full/runs_all.csv`
分 shard	`results/qkv_v_full/runs_s0..3.csv`
随机站点	`results/qkv_v_full/sites.csv`
总汇总	`results/qkv_v_full/summary.json`
数值汇总	`results/qkv_v_full/summary_numeric.csv`
按 bit 汇总	`results/qkv_v_full/summary_by_bit.csv`
clean 控制	`results/qkv_v_full/clean_controls/`
sham 控制	`results/qkv_v_full/sham.csv`
图	`results/qkv_v_full/figures/qkv_v_fullstack_summary.*`
图副本	`docs/figures/qkv_v_fullstack_summary.*`